تمرین ۱

نام استاد: دکتر فراهانی

نام دانشجو: ناهید حاتمی بلاسی

شماره دانشجویی: ۴۰۴۴۲۲۲۰۷

نام درس : داده کاوی پیشرفته

Analytical Questions

Q۱. Explain the “Dying ReLU” problem in deep fully connected networks. Mathemati cally, what condition causes a neuron to “die”? Why is Leaky ReLU or Parametric ReLU a potential solution? Are there any scenarios where a dying ReLU could be unintentionally beneficial, acting as a form of sparsity regularization? Explain your reasoning.

پاسخ) تابع فعال‌سازی relu به‌صورت $f(x)=max(۰,x)$ است، به‌طوریکه مشتق این تابع هنگامی که $x>۰$ برابر با ۱ و وقتی که $x<۰$ برابر با ۰ است. بنابراین این تابع در ناحیه مثبت، دارای گرادیان بدون مشکل و در شبکه آموزش سریع‌تر دارد، اما یک نورون زمانی از بین می‌رود که خروجی آن برای تمام ورودی‌های داده همیشه صفر باشد یعنی مقدار پیش‌فعال‌سازی نورون $z=w^{t}x+b$ برای تمام نمونه‌های داده منفی شود یعنی $f(z) = ۰$ در ناحیه منفی، مشتق ReLU برابر صفر است $\partial f/\partial fz=۰$. پس گرادیانی برای به‌روزرسانی وزن‌ها وجود ندارد و وزن‌های آن نورون دیگر تغییر نمی‌کنند،بنابراین نورون از بین می‌رود. این مشکل به دلیل نرخ یادگیری بزرگ یا مقداردهی اولیه نامناسب وزن‌ها رخ می‌دهد، یعنی وزن‌ها به‌گونه‌ای تغییر کنند که مقدار zبرای همه ورودی‌ها منفی شود. برای کاهش این مشکل جای اینکه شیب در ناحیه منفی صفر باشد، یک شیب کوچک غیرصفر داریم یعنی هنگامی که $x>۰$ برابر با x و وقتی که $x<۰$ برابر با αx است که α بسیار کوچک ولی به دلیل وجود این شیب کوچک در ناحیه منفی، گرادیان هرگز صفر نمی‌شود و نورون در آموزش دوباره فعال می‌شود. در روش prelu نیز همینطور است فقط مقدار α در طول آموزش توسط مدل یاد گرفته است. همچنین با توجه به پدیده dying relu زمانی که تعداد قابل توجهی نورون خروجی صفر می‌دهند، شبکه

حالت اسپارس می‌شود یعنی برای هر ورودی فقط تعداد کمی از نورون‌ها فعال هستند. بنابراین این اسپارس‌ها به عنوان implicit regularization هست ک باعث می‌شود مدل ویژگی‌های متنوعی یاد بگیرد ولی اگر تعداد زیادی از نورون‌ها غیر فعال شوند، ظرفیت مدل کاهش پیدا می‌کند و عملکرد شبکه افت می‌کند. بنابراین وجود مقدار کمی sparsity می‌تواند مفید باشد، اما مرگ تعداد زیادی نورون در شبکه معمولا نامطلوب است.

Q۲. Consider a very deep fully connected network with ۵۰ hidden layers, all using the sigmoid activation function. Explain precisely why the gradients in the earlier layers will approach zero, using the chain rule. How do architectural choices like residual connections (skip connections) or activation function choices like ReLU fundamen tally alter this gradient flow? Use mathematical intuition

پاسخ) تابع سیگموید به‌صورت $\sigma(x)= ۱/۱ + e^{-x}$ است که مشتقش به‌صورت $\sigma(x)(۱-\sigma(x))$ است، بیشترین مقدار مشتق سیگموید وقتی که $\sigma(x)=۰,۵$ برابر با $\sigma'(x)\leq ۰,۲۵$ که در حالت backpropagation که براساس قوانینchain rule رخ می‌دهد و گرادیان تابع خطا نسبت به وزن‌های لایه‌های اولیه شامل حاصل‌ضرب مشتق‌های لایه‌های بعدی است. برای یک شبکه با Lلایه، گرادیان نسبت به وزن‌های لایه اول $\frac{\sigma L}{\sigma w1} = \frac{\sigma L}{\sigma \alpha L} \prod_{l=۲}^{L} \frac{\sigma \alpha L}{\sigma \alpha L-۱}$ در یک شبکه با ۵۰ لایه، مقدار گرادیان $(۰,۲۵)^{۵۰} \approx ۸,۸ \times ۱۰^{-۳۱}$است. این مقدار چون کوچک باعث گرادیان در لایه‌های ابتدایی نزدیک به صفر شود. در نتیجه وزن‌های لایه‌های اولیه تقریباً به‌روزرسانی نمی‌شوند و شبکه قادر به یادگیری موثر در این لایه‌ها نخواهد بود.

دو راهکار مهم برای کاهش این مشکل شامل انتخاب تابع فعال‌سازی مناسب و تغییر معماری شبکه است. مشتق تابع relu در بخش مثبت برابر ۱ است. به همین دلیل وقتی پس‌انتشار انجام می‌شود، گرادیان بین لایه‌های مختلف بدون اینکه خیلی کوچک شود منتقل می‌شود و در نتیجه مشکل ناپدید شدن گرادیان تا حد زیادی کمتر می‌شود. دومین راهکار residual connections (skip connections) است که در معماری‌هایی همانند resnet وجود دارد که در لایه اول به‌صورت $y=F(x)+x$ نوشته می‌شودو گرادیانش نیز $\partial y/\partial x = F'(x)+۱$ است و وجود جمله ۱+ باعث می‌شود که حتی اگر $F'(x)$کوچک باشد، گرادیان همچنان بتواند در شبکه جریان پیدا کند و در واقع یک مسیر مستقیم برای انتقال گرادیان از لایه‌های بالاتر به لایه‌های پایین‌تر ایجاد می‌شود و مشکل ناپدید شدن گرادیان کاهش می‌یابد.

Q۳. The He (Kaiming) and Xavier (Glorot) initialization schemes are designed to keep the variance of activations and gradients stable across layers. However, the choice of initialization can also act as an implicit regularizer. Explain how an improperly small initialization scale (e.g., all weights ≈ ۰/۰۱) can lead to a form of regularization, but one that typically harms performance rather than helping. Contrast this with the explicit regularization of weight decay (L ۲regularization)

پاسخ)

روش‌های مقداردهی اولیه Xavier (Glorot) و He (Kaiming) داری اهداف اصلی حفظ پایداری واریانس فعال‌سازی‌ها و گرادیان‌ها در طول لایه‌های شبکه است تا از مشکلاتی مانند vanishing gradient یا exploding gradient جلوگیری شود. همچنین در مقداردهی اولیه مناسب، واریانس وزن‌ها بر اساس تعداد نورون‌های ورودی هر لایه تنظیم می‌کند. در مقداردهی اولیه He که برای توابع فعال‌سازی مانند relu طراحی شده است، واریانس وزن‌ها به صورت var(W)=۲/ nin تعریف شده است. در مقداردهی اولیه Xavier که معمولا برای توابعی مانند sigmoid یا tanh استفاده می‌شود، واریانس وزن‌ها var(W)=۲/ nout+ nin است. همچنین اگر وزن‌ها با مقیاس بسیار کوچک مقداردهی اولیه شوند خروجی هر لایه نیز بسیار کوچک خواهد شد. در این حالت سیگنال عبوری از لایه‌ها به شدت ضعیف می‌شود و شبکه رفتاری تقریبا خطی پیدا می‌کند و گرادیان‌ها نیز کوچک خواهند شد و به‌روزرسانی وزن‌ها بسیار کند انجام می‌شود.این وضعیت می‌تواند به نوعی implicit regularization شباهت داشته باشد، زیرا وزن‌ها در طول آموزش کوچک باقی می‌مانند و ظرفیت مدل برای یادگیری روابط پیچیده کاهش پیدا می‌کند. این نوع regularization مفید نیست، زیرا به جای جلوگیری از بیش‌برازش مدل توانایی کافی برای یادگیری الگوهای موجود در داده‌ها را ندارد و در نتیجه عملکرد آن کاهش یابد. در مقابل، weight decayیا L۲ regularization یک روش regularization explicit است که با اضافه کردن یک جمله جریمه به‌تابع هزینه، از بزرگ شدن بیش از حد وزن‌ها جلوگیری می‌کند.L=Ldata +λ∑w^۲ در این رابطه λشدت regularization را کنترل می‌کند. برخلاف مقداردهی اولیه بسیار کوچک که به صورت غیرمستقیم و کنترل‌نشده ظرفیت مدل را کاهش می‌دهد، L۲ regularizationبه شکل هدفمند اندازه وزن‌ها را محدود می‌کند و در نتیجه مدل الگوهای مهم داده را یاد بگیرد و از بیش‌برازش جلوگیری شود.

Practical Questions

در این پروژه از دیتاست Movies استفاده شده است که شامل ویژگی‌های متعددی درباره فیلم‌ها از جمله بودجه(budget) ، درآمد (revenue)، مدت زمان فیلم(runtime) ، میانگین امتیاز(vote Average) ، میزان محبوبیت (popularity) و سایر ویژگی‌ها که در جدول۱می‌باشد.

جدول ۱_ تعریف ویژگی‌ها (متغیرها)

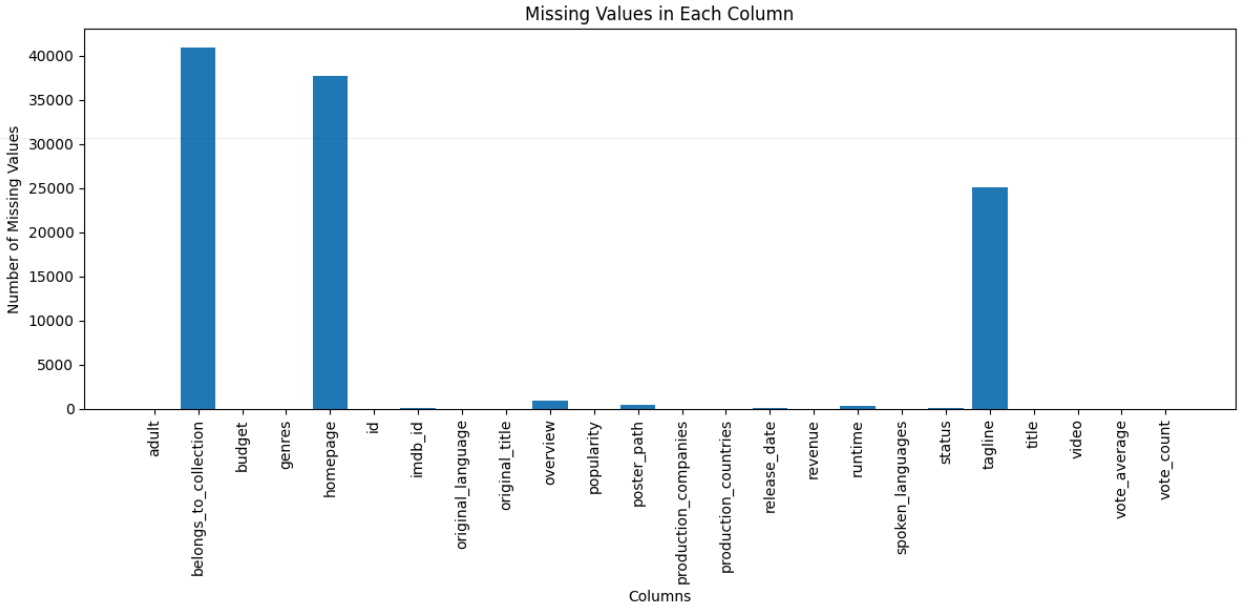
نام ویژگی	توضیح
adult (بزرگسال)	مشخص می‌کند که آیا فیلم دارای محتوای مخصوص بزرگسالان است یا خیر
belongs_to_collection (مجموعه)	اطلاعات مربوط به مجموعه یا فرنچایزی که فیلم به آن تعلق دارد (در صورت وجود)
budget (بودجه)	بودجه تولید فیلم به دلار
genres (ژانرها)	لیستی از ژانرهای فیلم مانند کمدی، درام، انیمیشن و غیره
homepage (صفحه رسمی)	لینک وب‌سایت رسمی فیلم (در صورت وجود)
id (شناسه داخلی)	شناسه یکتای فیلم در پایگاه داده
imdb_id (شناسه IMDb)	شناسه اختصاصی فیلم در وب‌سایتIMDb
original_language (زبان اصلی)	زبان اصلی تولید فیلم مانند en برای انگلیسی
original_title (عنوان اصلی)	عنوان فیلم به زبان اصلی تولید
overview (خلاصه داستان)	توضیح یا خلاصه‌ای کوتاه از داستان فیلم
popularity (محبوبیت)	شاخص عددی محبوبیت فیلم بر اساس تعامل کاربران
poster_path (پوستر)	مسیر فایل تصویر پوستر فیلم
production_companies (شرکت‌های تولیدکننده)	لیست شرکت‌هایی که در تولید فیلم مشارکت داشته‌اند
production_countries (کشورهای تولیدکننده)	کشورهای محل تولید فیلم
release_date (تاریخ انتشار)	تاریخ رسمی اکران فیلم
revenue (درآمد)	میزان درآمد حاصل از فروش فیلم به دلار
runtime (مدت زمان)	مدت زمان فیلم بر حسب دقیقه
spoken_languages (زبان‌های فیلم)	زبان‌هایی که در فیلم صحبت می‌شود
status (وضعیت انتشار)	وضعیت انتشار فیلم مانند Released یاPost Production
tagline (شعار تبلیغاتی)	جمله یا شعار تبلیغاتی فیلم
title (عنوان)	عنوان فیلم نسخه نمایشی یا بین‌المللی
video (ویدئویی بودن)	مشخص می‌کند که آیا فیلم به صورت ویدیویی منتشر شده است یا خیر
vote_average (میانگین امتیاز)	میانگین امتیاز کاربران به فیلم
vote_count(تعداد آرا)	تعداد کل رای‌های ثبت‌شده برای فیلم

بخش اول) Exploratory Data Analysis (EDA) and Feature Engineering

در گام ۱ تحلیل اکتشافی داده‌ها، ابتدا داده‌های گمشده و سطرهای تکراری را بررسی می‌شود (در نظر داریم که دید کلی راجب دیتا با استفاده از تابعی در اول کد بررسی شده است .) در این دیتاست ۱۳ سطر تکراری وجود داشت که آن‌ها را حذف کرده‌ایم.

در این مرحله مقادیر گمشده در دیتاست مورد بررسی قرار گرفت به‌طوریکه بررسی اولیه نشان داد که در برخی از ستون‌ها تعداد قابل توجهی مقدار گمشده وجود دارد. در صورتی که این مقادیر به صورت سطری حذف می‌شدند، بخش قابل توجهی از داده‌ها از بین می‌رفت و حجم دیتاست بسیار کاهش پیدا می‌کرد. به همین دلیل در مرحله تحلیل داده‌های عددی و بخش خوشه‌بندی، مدیریت مقادیر گمشده به صورت انتخابی انجام شد و تنها در ستون‌هایی (۶ ستون نیومریک) که برای تحلیل ضروری بودند، مقادیر گمشده حذف شدند. در بخش تحلیل شبکه این مقادیر گمشده به صورت ستونی (هر ویژگی با توجه به مقادیر گمشده و شرایط راهکارهایی صورت گرفت) در نظر گرفته شدند تا از کاهش حجم دیتاست جلوگیری شود.

همچنین در این دیتاست دو نوع مقدار گمشده وجود دارد. نوع اول مقادیری که به صورت NA ثبت شده‌اند و نشان‌دهنده نبود داده هستند، و نوع دوم مقادیری که ظاهرا مقدار دارند اما در واقع نشاندهنده‌ی ثبت نشدن اطلاعات می‌باشند.(جلوتر بررسی بیشتری انجام داده می‌شود.)



شکل۱- نمودار مقادیر گمشده در هر ویژگی در دیتاستmovies

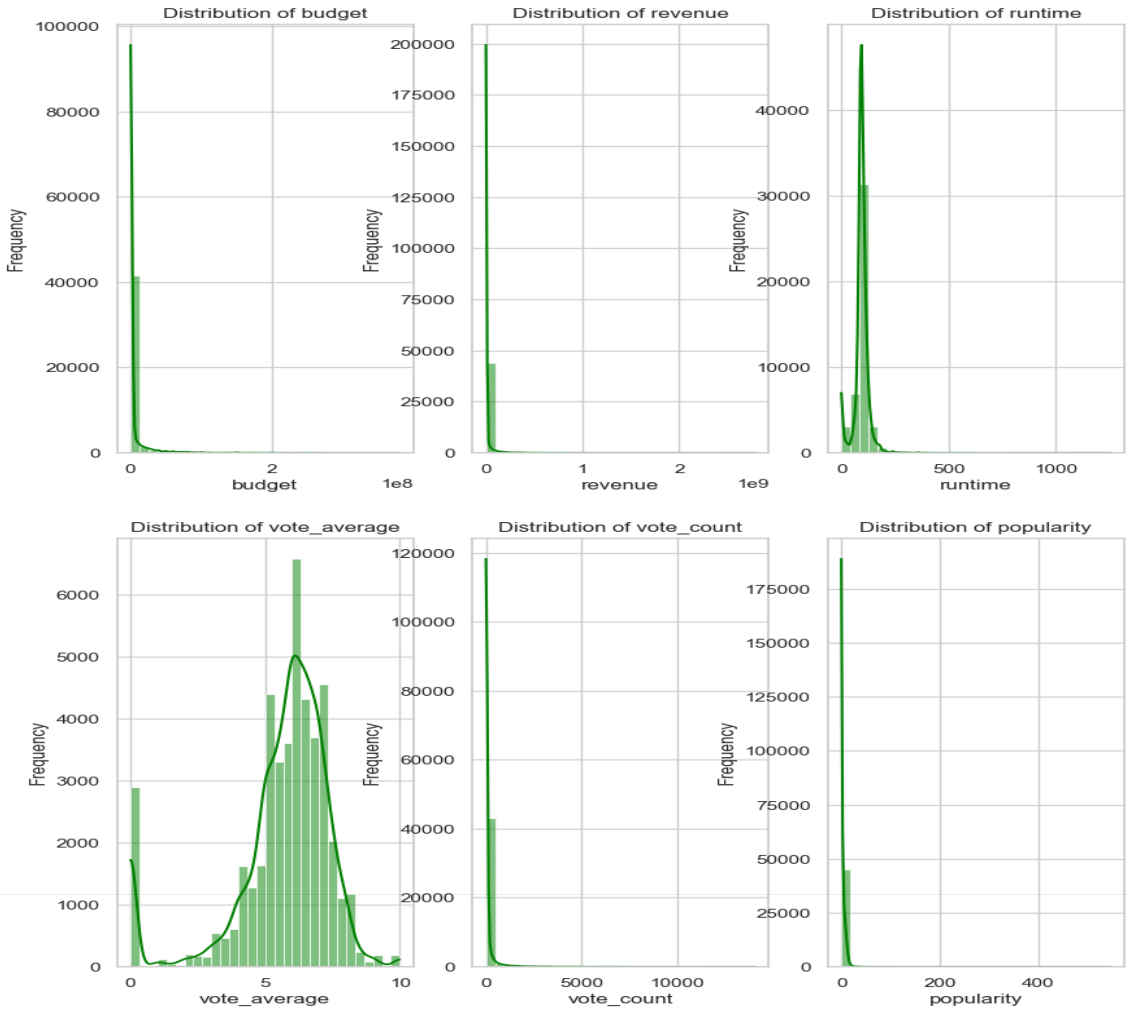
بر اساس این بررسی، مشاهده شد که برخی از ستون‌ها دارای تعداد زیادی مقدار گمشده هستند. با این حال، حذف این مقادیر به صورت سطری امکان‌پذیر نبود، زیرا در این صورت بخش قابل‌توجهی از داده‌های موجود در سایر ویژگی‌ها نیز از بین می‌رفت. به‌ویژه در ستون‌هایی مانندhomepage ، belongs_to_collectionو tagline تعداد مقادیر گمشده بسیار زیاد است و حذف سطرهای مربوط به آن‌ها می‌توانست منجر به کاهش قابل توجه حجم دیتاست شود.

بنابراین در این بخش ویژگی‌های budgetوrevenueوruntimeوvote_averageوvote_countو popularity مورد بررسی قرار گرفت و با توجه به درصد مقادیر گمشده نوع اول که به صورت NA ثبت شده‌اند، در این ویژگی‌ها حذف شده‌اند.

جدول۲- نتایج آمار توصیفی برخی ویژگی‌ها

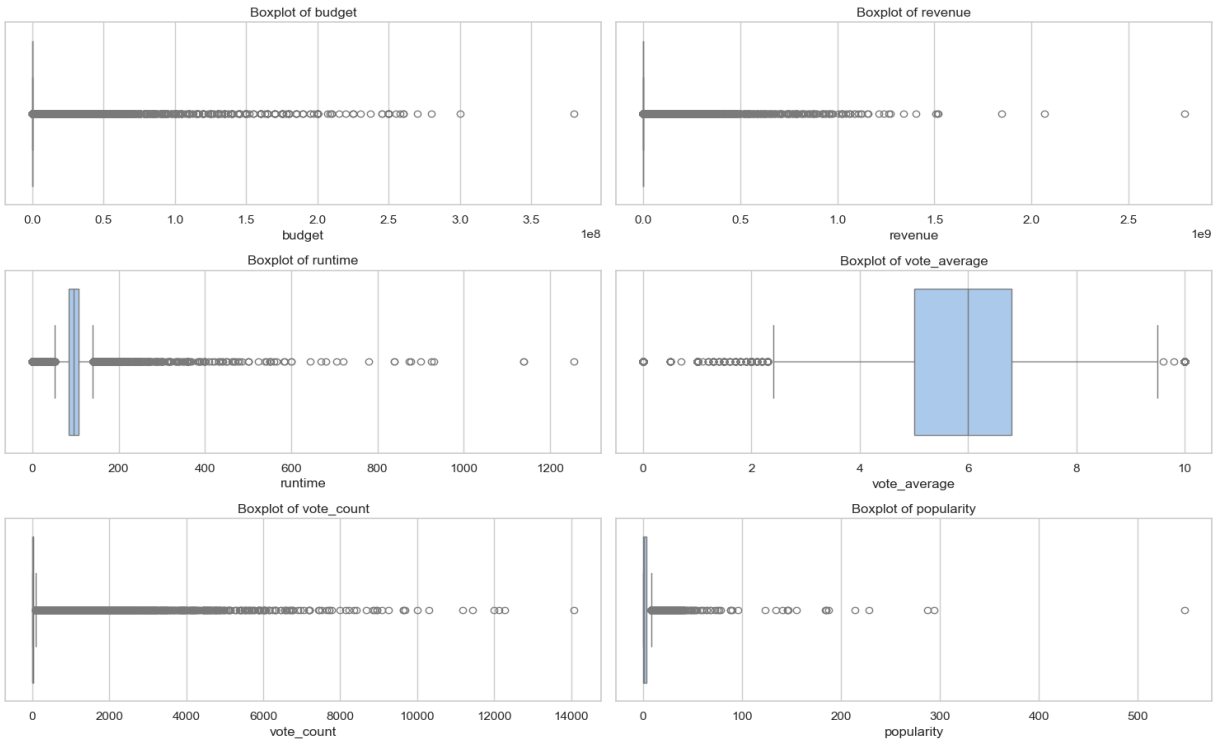
شاخص	budget	revenue	Runtime	vote_average	vote_count	Popularity
count	۴۵۱۹۰.۰۰	۴۵۱۹۰.۰۰	۴۵۱۹۰.۰۰	۴۵۱۹۰.۰۰	۴۵۱۹۰.۰۰	۴۵۱۹۰.۰۰
mean	۴۲۴۹۶۲۳.۰۰	۱۱۲۷۶۲۳۰.۰۰	۹۴.۱۲	۵.۶۳	۱۱۰.۵۳	۲.۹۴
std	۱۷۴۷۳۶۵۰.۰۰	۶۴۵۱۸۳۱۰.۰۰	۳۸.۴۱	۱.۹۱	۴۹۲.۷۱	۶.۰۲
min	۰.۰۰	۰.۰۰	۰.۰۰	۰.۰۰	۰.۰۰	۰.۰۰
۲۵٪	۰.۰۰	۰.۰۰	۸۵.۰۰	۵.۰۰	۳.۰۰	۰.۳۹
۵۰٪	۰.۰۰	۰.۰۰	۹۵.۰۰	۶.۰۰	۱۰.۰۰	۱.۱۴
۷۵٪	۰.۰۰	۰.۰۰	۱۰۷.۰۰	۶.۸۰	۳۴.۰۰	۳.۷۲
max	۳۸۰۰۰۰۰۰.۰۰	۲۷۸۷۹۶۵۰۰۰.۰۰	۱۲۵۶.۰۰	۱۰.۰۰	۱۴۰۷۵.۰۰	۵۴۷.۴۹

در جدول ۲ ، نتایج آمار توصیفی آورده شده است به‌طوریکه تعداد مقادیر در هر ویژگی برابر با ۴۵۱۹۰ است. میانگین بودجه فیلم‌ها ۴۲۴۹۶۲۳ دلار و میانگین درآمد آن‌ها ۱۱۲۷۶۲۳۰ دلار است اما بیشترین بودجه ۳۸۰۰۰۰۰۰۰ دلار و درآمد ۲۷۸۷۹۶۵۰۰۰ دلار گزارش شده است. همچنین مقادیر چارک‌ها نشان می‌دهد که در دامنه میان چارکی بودجه و درآمد برابر با صفر حاصل شده است که می‌تواند نشان‌دهنده ثبت نشدن اطلاعات واقعی برای برخی فیلم‌ها باشد. در ویژگی مدت زمان فیلم نیز میانگین ۹۴.۱۲ دقیقه است اما با توجه به دامنه میان‌چارکی در این ویژگی بیشتر فیلم‌ها در بازه ۸۵ تا ۱۰۷ دقیقه ساخته شده است. . همچنین میانگین امتیاز کاربران به فیلم‌ها برابر با ۵. ۶۳ است که نشان می‌دهد بیشتر فیلم‌ها امتیازی در محدوده متوسط دریافت کرده‌اند البته رنج امتیازدهی در بازه ۰ تا ۱۰ است. میانگین تعداد رای‌ها حدود ۱۱۰ رای است، اما مقدار بیشینه آن ۱۴۰۷۵ رای است که نشان‌دهنده وجود برخی فیلم‌های بسیار پرمخاطب دراین دیتاست می‌باشد. شاخص محبوبیت نیز دارای میانگین ۲.۹۴ و انحراف معیار ۶.۰۲ است که بیانگر پراکندگی زیاد محبوبیت میان فیلم‌ها می‌باشد به‌طوریکه کمترین امتیاز ۰ و بیشترین محبوبیت حدود ۵۴۷.۴۹ می‌باشد.



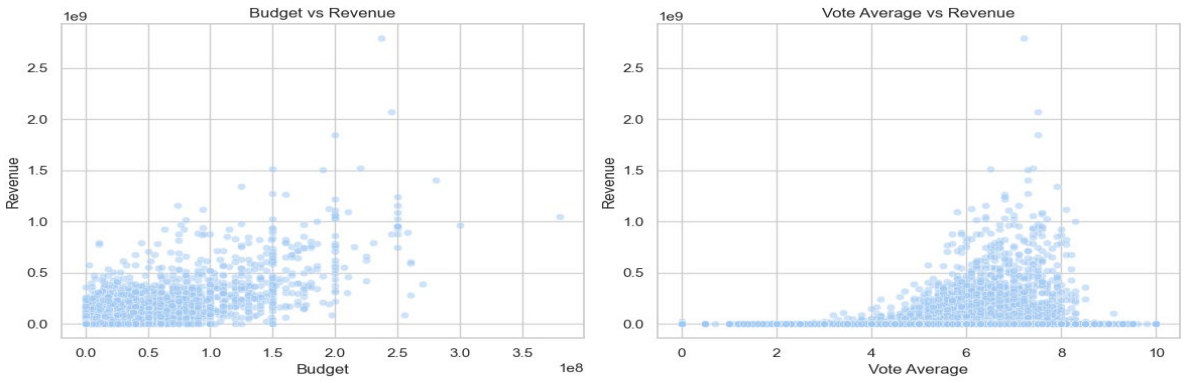
شکل۲ – نمودار هیستوگرام برخی ویژگی‌ها (revenueوruntime و vote_averageو vote_countو popularity)

در شکل ۲ نمودار هیستوگرام مربوط به برخی ویژگی‌های عددی رسم شده است به‌طوریکه در نمودار بودجه (بالا در سمت چپ) نشان می‌دهد که بسیاری از فیلم‌ها بودجه بسیار پایینی دارند و تعداد کمی از فیلم‌ها با بودجه‌های بسیار بالا ساخته شده‌اند اما با توجه به مقدار صفر در این ویژگی نشان می‌دهد برای بسیار از فیلم‌ها اطلاعات بودجه ثبت نشده است و به همین دلیل دچار چوله به راست شدید در این نمودار رخ داده است. همچنین این الگو در نمودار درآمد (بالا در سمت وسط) نیز تکرار شده است، به‌طوریکه بسیاری از فیلم‌ها درآمد، ثبت نشده است و مقدار کمی از فیلم‌ها درآمد بالایی دارند.د در این نمودار نیز چولگی راست شدید نیز دیده می‌شود. به همین ترتیب در نمودارهای تعداد رای (پایین در سمت وسط) و شاخص محبوبیت (پایین سمت راست) نیز دارای مقادیر بسیار زیاد صفر که نشاندهنده‌ی عدم ثبت اطلاعات هستند و همچنین چولگی بسیار شدید نیز مشاهده می‌شود. در نمودار میانگین امتیاز (پایین در سمت چپ) مشاهده می‌شود که اغلب فیلم‌ها امتیازات متوسط تا خوب گرفته‌اند زیرا امتیازها دارای توزیع نزدیک به نرمال هستند ولی مقدار صفر نیز نشاندهنده‌ی عدم ثبت اطلاعات است زیرا نمیتوان میانگین امتیاز یک فیلم صفر در نظر گرفت. همچنین در نمودار مدت‌زمان فیلم‌ها (بالا سمت راست) توزیع داده‌ها نسبتا متمرکزتر است و اگرچه تعداد کمی از فیلم‌ها زمان بسیار کوتاه یا بسیار طولانی دارند، اما برخلاف سایر ویژگی‌ها مقدار صفر یا عدم ثبت اطلاعات در این ستون مشاهده نمی‌شود.



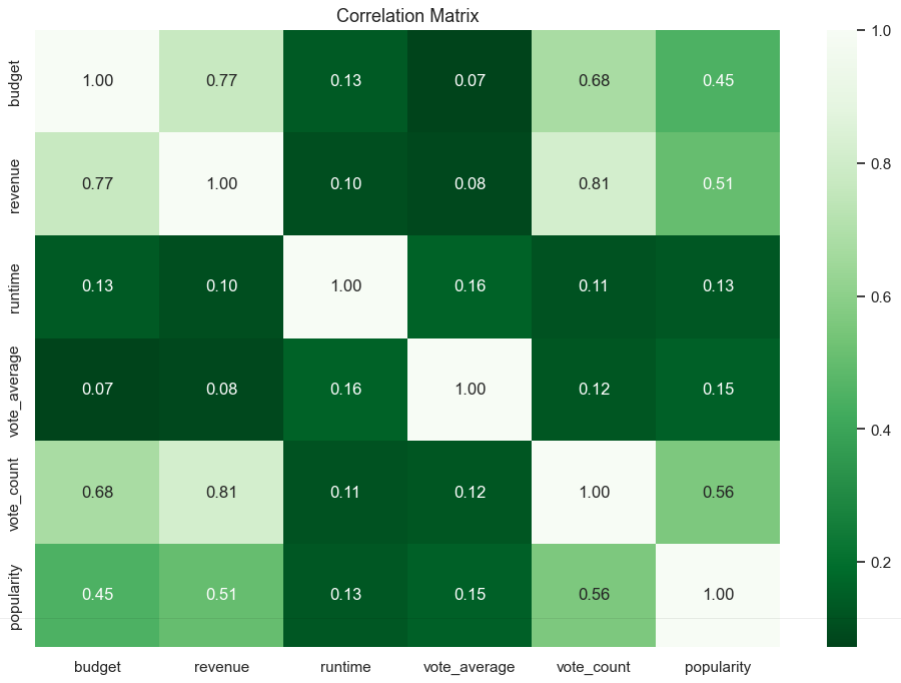
شکل۳- نمودار جعبه‌ای برخی ویژگی‌ها (revenueوruntime و vote_averageو vote_countو popularity)

بر اساس شکل ۳، در نمودار بودجه (بالا در سمت چپ) و درآمد (ردیف اول در سمت راست) و تعداد رای (ردیف سوم در سمت چپ) و شاخص محبوبیت (ردیف سوم در سمت راست) مشاهده می‌شود که تعداد زیادی نقطه پرت در مقادیر بالا وجود دارد و اکثر داده‌ها در بازه پایین هستند. این موضوع در شکل ۲ نیز بررسی شد و علت این موضوع وجود مقادیر صفر به‌عنوان داده گمشده است که باعث ایجاد توزیعی با چولگی شدید به راست و تعداد زیاد مقادیر پرت شده است. در نمودار مدت‌زمان فیلم‌ها (ردیف دوم در سمت چپ) با وجود اینکه بیشتر داده‌ها در دامنه میان چارکی قرار دارند، بسیاری از نقاط پرت در قسمت راست این نمودار دیده می‌شود. در نمودار میانگین امتیازات (ردیف دوم سمت راست) دارای تقریبا توزیع نرمال است، در این نمودار تعداد قابل توجهی نقاط پرت دیده نمی‌شود.



شکل۴- نمودار پراکندگی درآمد بر حسب بودجه و میانگین امتیاز

در شکل ۴ مشاهده می‌شود که در نمودار درآمد برحسب بودجه (سمت چپ) روند کلی مثبت است به‌طوریکه وقتی بودجه افزایش می‌یابد احتمال اینکه درآمد بیشتر کسب شود افزایش می‌یابد. همچنین در این نمودار پراکندگی مقادیر بسیار زیاد است و همچنین وجود مقادیر پرت سبب الگوی غیر خطی در رفتار این دو متغیر شده است. در نمودار درآمد با میانگین امتیاز (سمت راست) دیده می‌شود میانگین امتیاز بالاتر سبب درآمد بالاتر می‌شود ولی در مواردی نیزمیانگین امتیاز بالا حاصل درآمد بالا نشده است، بنابراین رابطه خطی میان متغیر درآمد و میانگین امتیاز وجود ندارد.

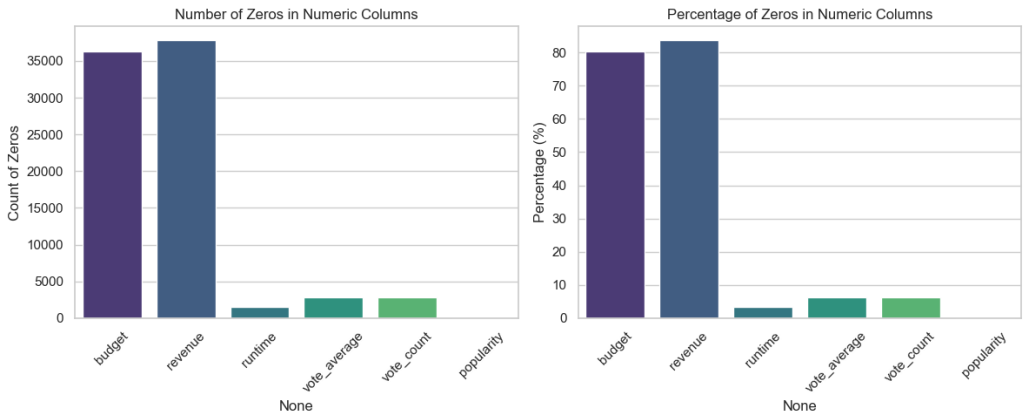


شکل ۵ – نمودار همبستگی برخی ویژگی‌ها(revenueوruntime و vote_averageو vote_countو popularity)

در شکل ۵ نمودار همبستگی نشان می‌دهد قوی‌ترین روابط خطی بین متغیرها مربوط به درآمد با تعداد رای (۰.۸۱) و بودجه (۰.۷۷) است. همچنین بودجه با تعداد رای (۰.۶۸) و شاخص محبوبیت (۰.۴۵) ارتباط قابل توجهی دارد، اما میانگین امتیاز با درآمد و سایر متغیرها همبستگی بسیار ضعیفی دارد. همچنین مدت زمان فیلم نیز با هیچ متغیری همبستگی قابل توجهی ندارد. بنابراین درآمد بیشتر تحت‌تاثیرعواملی مانند بودجه، شاخص محبوبیت و تعداد رای است.

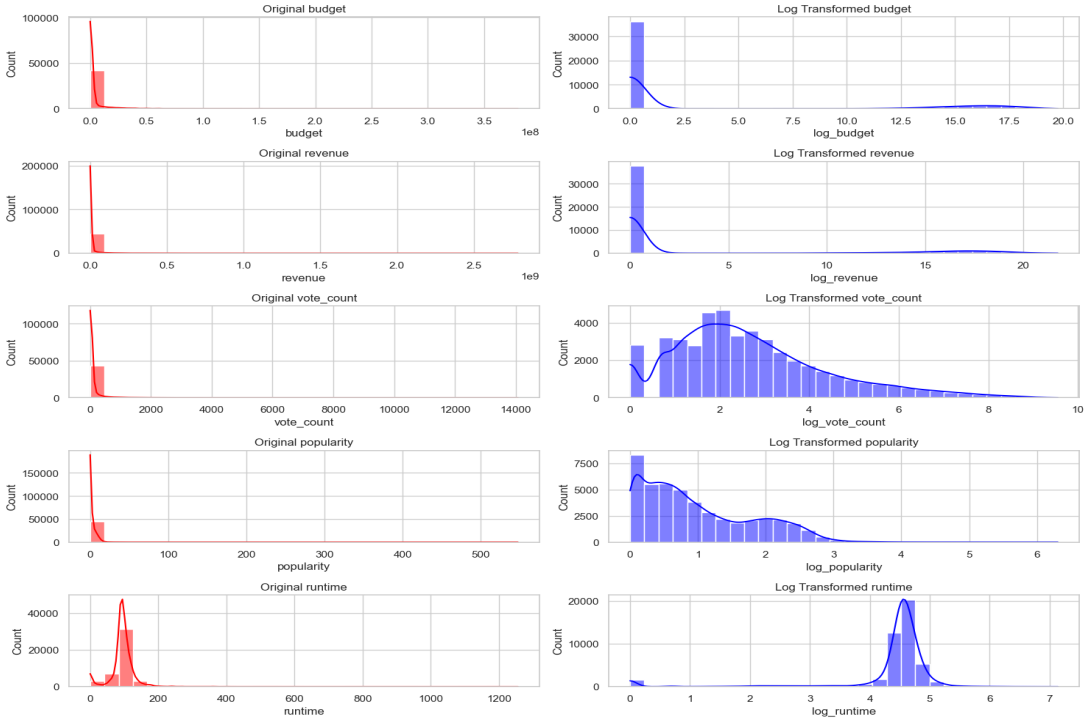
با توجه به نتایج در بخش تحلیل اکتشافی داده‌ها می‌بایست مقدار صفر که در برخی ویژگی‌ها به معنای عدم ثبت اطلاعات، کنترل شود. بنابراین از داده اصلی چند کپی گرفته می‌شود تا با آزمایش کردن به‌نتیجه مطلوب رسید. همچنین چولگی ویژگی‌ها نیز می‌بایست کنترل شود.

راهکار اول : حذف کردن مقادیر صفر (عدم ثبت اطلاعات)



شکل۶- نمودار میله‌ای تعداد مقدار صفر و درصد مقدار صفر

در شکل ۶ مشاهده می‌شود که در بعضی از ویژگی‌ها همانند بودجه وجود مقدار صفر حدود ۸۰ درصد و ویژگی درآمد بیش از ۸۰ درصد را تشکیل می‌دهند. بنابراین حذف کردن مقادیر صفر در ویژگی‌ها کار مناسبی نمی‌باشد و باعث کاهش بیش از حد دیتاست می‌شود و بخش قابل‌توجهی از اطلاعات را از بین می‌برد. با اینکه درصد مقدار صفر در برخی ویژگی‌ها همانند مدت زمان فیلم و میانگین امتیاز کم است اما به‌دلیل از دست ندادن اطلاعات در این ویژگی‌ها نیز حذف کردن راهکار مناسبی نخواهد بود. در ویژگی تعداد رای صفر نشاندهنده‌ی عدم‌ثبت اطلاعات نبود و در یک سری از فیلم‌ها ممکنه که تعداد رای وجود نداشته باشد.



شکل ۷- نمودار هیستوگرام قبل و بعد لگاریتم برخی ویژگی‌ها

همان‌طور که در شکل ۷ مشاهده می‌شود، نمودار هیستوگرام ویژگی‌ها هم در حالت اولیه و هم پس از اعمال تبدیل لگاریتمی ترسیم شده است. بررسی این نمودارها نشان می‌دهد که در برخی ویژگی‌ها مقدار صفر مشاهده می‌شود که در این تحلیل به‌عنوان مقدار نامعتبر یا معادل داده‌ی گمشده در نظر گرفته شده و لازم است پیش از انجام تبدیل‌ها مدیریت شود. پس از جایگزینی این مقادیر با یک مقدار مناسب، اعمال تبدیل لگاریتمی بر برخی ویژگی‌ها باعث کاهش میزان چولگی توزیع و متعادل‌تر شدن داده‌ها شده است. این موضوع می‌تواند به بهبود کیفیت تحلیل‌های بعدی، از جمله روش‌های خوشه‌بندی، کمک کند. همچنین برای ویژگی مدت زمان مشاهده شد که استفاده از تبدیل لگاریتمی به بهبود قابل توجهی در توزیع داده‌ها منجر نمی‌شود و میبایست پر کردن مقدار مناسب برای مقادیر صفر و سپس به‌کارگیری روش Winsorization برای کنترل مقادیر پرت است که در نهایت توزیع داده را پایدارتر می‌کند، استفاده شود.

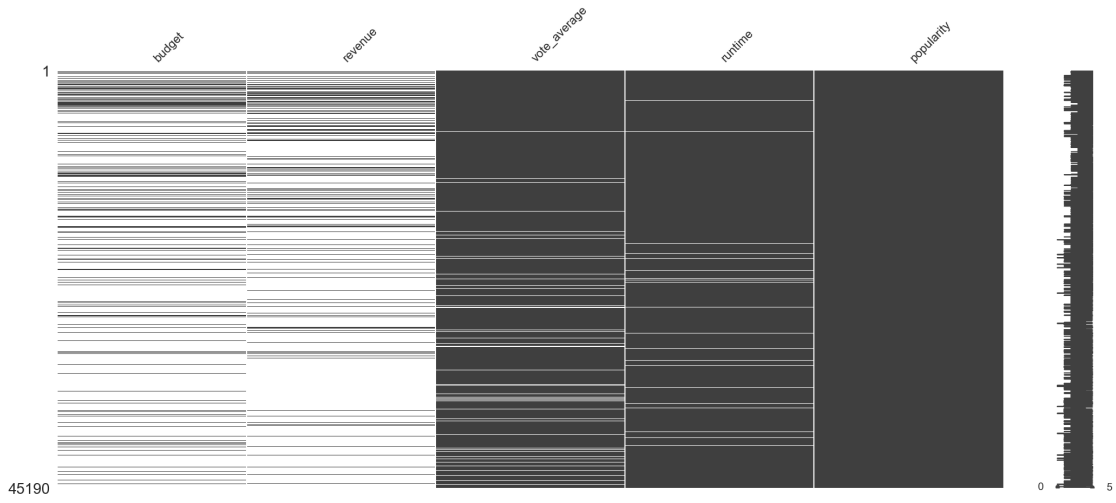
راهکار دوم : پرکردن مقادیر صفر (عدم ثبت اطلاعات)

در این رویکرد ابتدا مقادیر صفر تبدیل به مقادیر گمشده (na) شده‌اند تا بتوان آن‌ها را با مقدار جایگزین پرنمود.

جدول۳ – درصد مقادیر صفرهای عدم ثبت اطلاعات

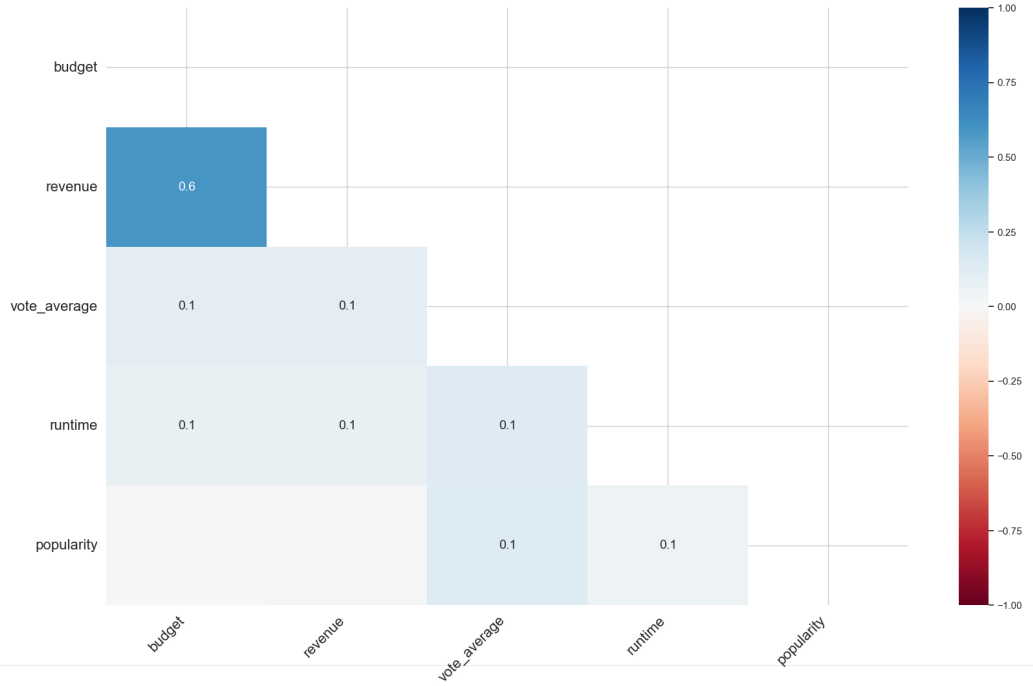
فیچر	درصد مقدار صفر(عدم ثبت اطلاعات)
budget	۸۰.۳۵۱۸۴۸٪
revenue	۸۳.۶۲۴۶۹۶٪
vote_average	۶.۴۱۲۹۲۳٪
Runtime	۳.۴۴۷۶۶۵٪
popularity	۰.۱۳۲۷۷۳٪

در جدول۳، درصد مقادیر صفرهای عدم ثبت اطلاعات گزارش شده است. بیشترین درصد گمشدگی مربوط به بودجه و درآمد و کمترین درصد گمشدگی مربوط به شاخص محبوبیت و زمان فیلم است.



شکل ۸ - نمایش الگوی داده‌های گمشده در برخی ویژگی‌ها

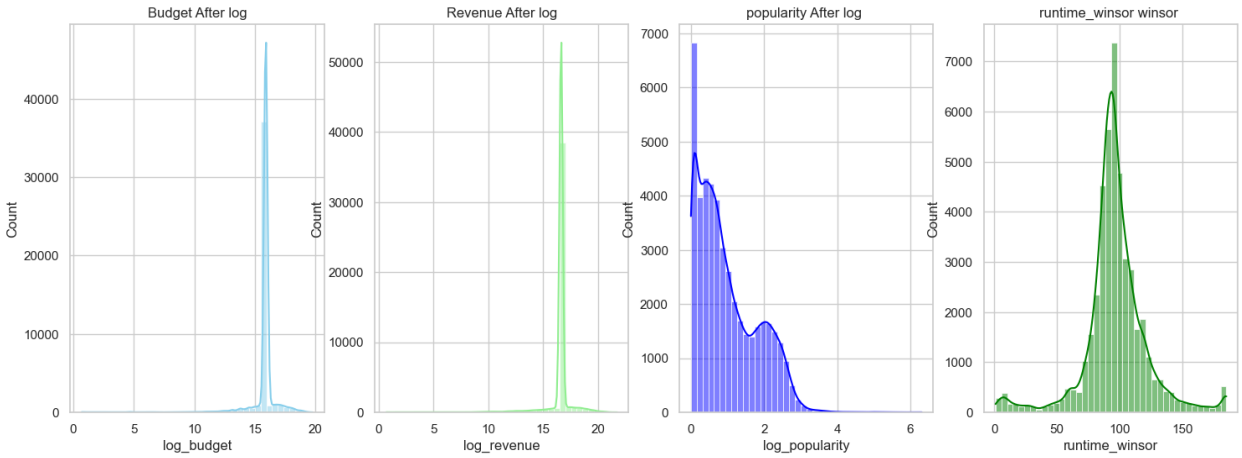
در شکل۸، نمودار وضعیت داده‌های گمشده مربوط به‌ویژگی‌های مختلف فیلم‌ها از جمله budget، revenue، vote_average، runtimeو popularityرا نشان می‌دهد. همان‌طور که در جدول ۲ اشاره شد دو ویژگی بودجه و درآمد دارای بیشترین مقادیر گمشده هستند، به‌طوری‌که بخش قابل‌توجهی دارای عدم اطلاعات بودجه و درآمد هستند. همچنین همچنین ویژگی‌های میانگین امتیاز و زمان فیلم و شاخص محبوبیت نیز دارای مقادیر گمشده کمتری هستند و در حال حاضر ویژگی‌های قابل‌اعتمادتری هستند.



شکل۹- همبستگی بین الگوهای مقادیر گمشده (صفر عدم ثبت اطلاعات)

در شکل۹، میزان همبستگی بین الگوهای مقادیر گمشده نشان داده شده است. بیشترین مقدار همبستگی، بین ویژگی‌های بودجه و درآمد است. بنابراین وقتی مقادیر بودجه وجود ندارد، در بسیاری از مواقع مقادیر درآمد نیز وجود ندارد. بنابراین دو ویژگی درآمد و بودجه وابسته هستند. سایر ویژگی‌ها همبستگی‌ها حدودا ۰٫۱ دارند، که نشان‌دهنده‌ی الگوی گمشده در ویژگی‌های زمان فیلم و شاخص محبوبیت و میانگین امتیاز مستقل از ستون‌های دیگر است.

همچنین نتیجه آزمون Little MCAR با پی‌مقدار برابر ۱ نشان داد که این داده‌ها به‌صورت تصادفی (MCAR) گمشده‌اند و هیچ الگوی وابستگی معناداری با سایر متغیرها ندارند. بنابراین، پس از این مرحله، داده‌های ناقص با مقدار میانه پر شدند و برای ویژگی‌ها نیز یک شاخص جداگانه (missing Indicator) جهت ردیابی اثر گمشده بودن ایجاد گردید. سپس با اعمال تبدیل لگاریتم و تبدیل Winsorization نمودارهای شکل ۱۰ حاصل شده است.



شکل ۱۰ – تبدیل‌های logaritm , winsorization به‌روی برخی ویژگی‌ها

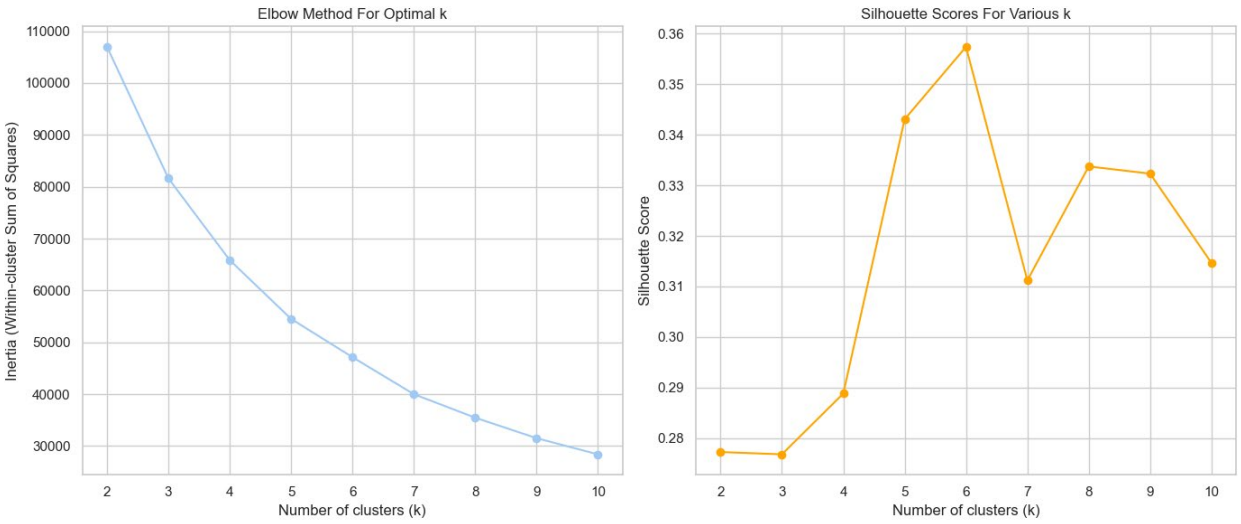
بر اساس شکل ۱۰، تبدیل لگاریتم به‌روی ویژگی‌های بودجه و درآمد و شاخص محبوبیت و تبدیل winsorization به‌روی ویژگی زمان فیلم اعمال شد. پس از اعمال تبدیل لگاریتمی توزیع این ویژگی‌ها که در ابتدا دارای چولگی شدید و مقادیر پرت شدیدی داشتند، به‌صورت نرمال‌تر و متمرکزتر شدند. همچنین در ویژگی زمان فیلم از روش winsorization استفاده شد که مقادیر پرت در توزیع را تعدیل می‌کند و در نتیجه پایداری بیشتری در توزیع نرمال حاصل می‌شود.

بخش سوم) Clustering Analysis

در این بخش بر اساس صورت مسئله سه ویژگی بودجه ، مدت‌زمان فیلم و میانگین امتیاز به‌عنوان متغیرهای ورودی الگوریتم k-means انتخاب شدند. بنابراین باتوجه که این ویژگی‌ها درمقیاس‌های متفاوتی قرار دارند و شامل مقادیر گمشده و پرت هستند، پیش‌پردازش داده‌ها پیش از اعمال خوشه‌بندی انجام شد و بررسی مقادیر صفر که به معنای عدم ثبت اطلاعات بود نیز اعمال کردیم. در نهایت، این سه ویژگی‌ها با استفاده از روش standard scaling نرمال‌سازی شدند تا محاسبه فاصله‌ها در الگوریتم k-means به درستی اجرا شود. (همچنین در این قسمت از missing indicator استفاده نشده است زیرا در خوشه‌بندی هدف پیش‌بینی نیست.) همچنین برای جلوگیری از نشت اطلاعات و پیش‌بینی که در بخش خوشه‌بندی وجود ندارد از متغیر درآمد به هیچ وجه نباید استفاده کرد.

روش اول) k-means clustering

برای تعیین تعداد بهینه‌ی خوشه‌ها، الگوریتم k-means با مقادیر مختلف k از ۲ تا ۱۰ اجرا شد. پس از نرمال‌سازی ویژگی‌ها با standardscaler، برای هر مقدار k، مقادیر مجموع فاصله درون‌خوشه‌ای و تفکیک بین خوشه‌ها محاسبه گردید و با مقایسه‌ی این دو شاخص، مقدار بهینه‌ی k انتخاب می‌شود.



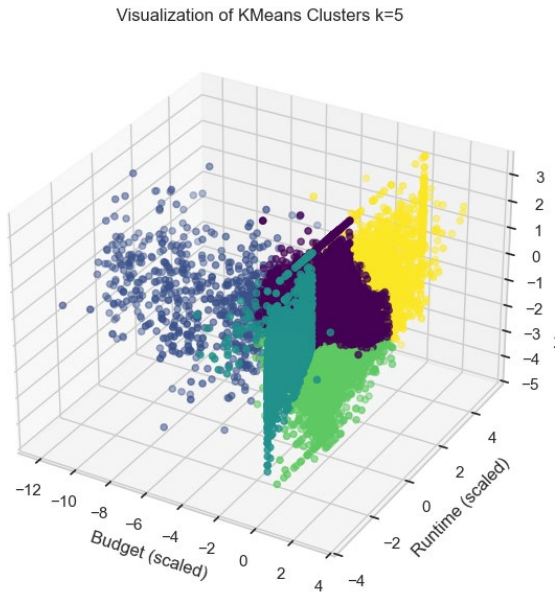
شکل ۱۱ – نمودار تعیین k الگوریتم k-means با استفاده از روش elbow و شاخص silhouette

در شکل ۱۱ نمودار تعیین k الگوریتم k-means با استفاده از روش elbow و شاخص silhouette نشان می‌دهد. با افزایش تعداد خوشه در نمودار سمت چپ نرخ کاهش می‌یابد و نقطه شکست در ۵ و ۶ است. در نمودار سمت راست نیز بالاترین مقدار این شاخص در حدود ۶, ۵ است که ساختار خوشه‌ها در این نقطه بیشترین تفکیک جداسازی و کمترین هم‌پوشانی را دارند. اگرچه بیشترین مقدار Silhouette در k=٦ به دست آمد، اما اختلاف آن با k=٥ خیلی کم است. بنابراین برای جلوگیری از ایجاد خوشه‌های مصنوعی و ساده‌تر ماندن مدل، الگوریتم k-means با تعداد خوشه‌ها ۵ اجرا شد.

جدول ۴– بررسی میانگین ویژگی‌ها در هر خوشه (مدل k-means)

cluster_label	log_budget	runtime_winsor	vote_average
۰	۱۵.۸۷	۹۶.۸۶	۶.۵۹
۱	۷.۵۷	۸۶.۷۰	۵.۹۰
۲	۱۵.۸۳	۳۴.۱۶	۶.۵۸
۳	۱۵.۸۵	۹۳.۰۹	۴.۶۳
۴	۱۶.۲۹	۱۴۹.۵۶	۶.۶۶

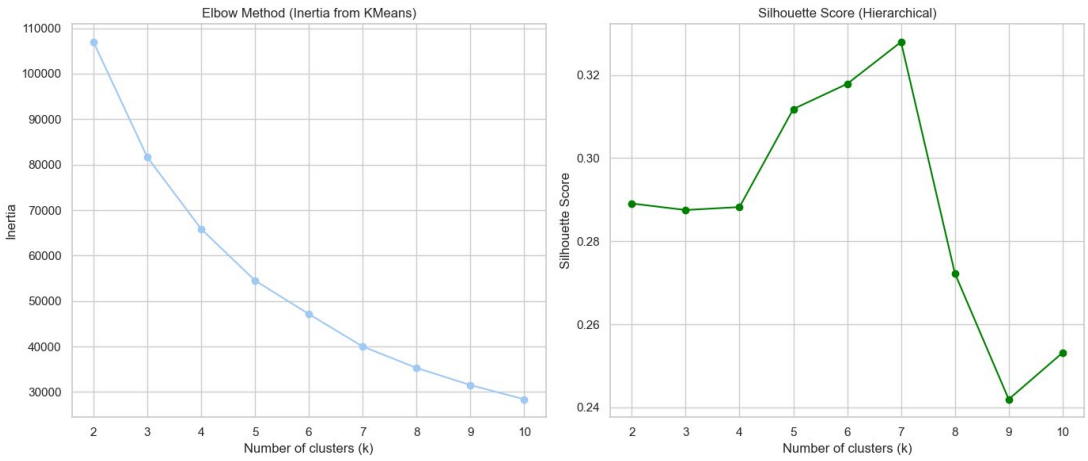
در جدول۴، بررسی میانگین ویژگی‌ها در هر خوشه گزارش شده است. به‌طوریکه خوشه اول با برچسب ۰ دارای فیلم‌هایی با میانگین بودجه بالا(۱۵.۸۷)، مدت زمان متوسط (۹۶.۸۶) و میانگین امتیاز خوب (۶.۵۹) حاصل شده است. خوشه دوم با برچسب ۱ فیلم‌هایی با میانگین بودجه بسیار پایین‌تر به نسبت دیگر خوشه‌ها و میانگین مدت زمان کمی کوتاه‌تر(به نسبت خوشه‌های دیگر) را شامل می‌شود اما در این خوشه میانگین امتیاز خوبی شامل می‌شود. خوشه سوم نیز با برچسب ۲ دارای میانگین بودجه بالایی (۱۵.۸۳) و میانگین زمان فیلم بسیار کوتاه‌تری به نسبت خوشه‌های دیگر (۳۴.۱۶) و میانگین امتیاز (۶.۵۸) خوبی دارد. خوشه چهارم با برچسب ۳ دارای میانگین بودجه و متوسط زمان فیلم، بالایی دارد ولی میانگین امتیاز بسیار پایین (۴.۶۳) به نسبت دیگر خوشه‌ها دارد. در خوشه پنجم نیز با برچسب۴ میانگین هر سه ویژگی بسیار بالاست. بنابراین بیشترین تاثیر در تفکیک خوشه‌ها دو ویژگی بودجه و زمان فیلم دارند و گاهی نیز میانگین امتیاز کاربران تاثیر داشته است.



شکل ۱۲- نمودار خوشه‌های الگوریتم k-means برای k=۵

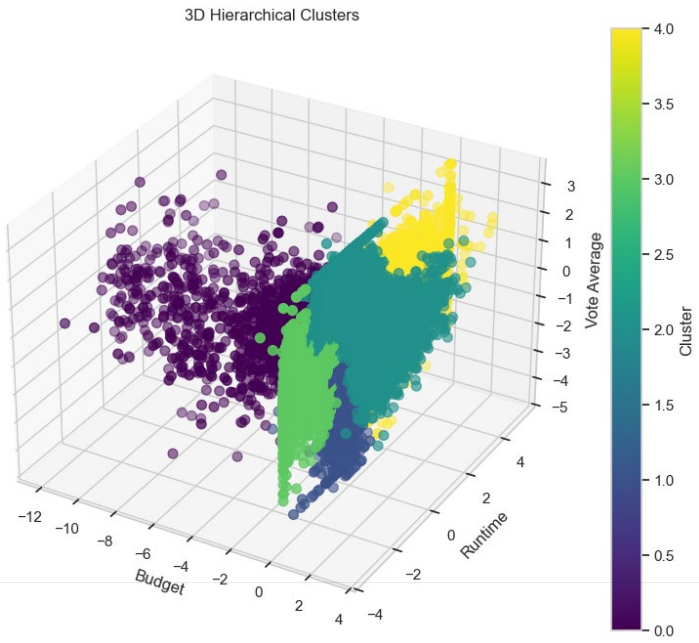
در شکل ۱۲ مشاهده می‌شود که ۵ خوشه متمایز الگوریتم k-means رسم شده است به‌طوریکه محورx بودجه و محور y زمان فیلم و محور z میانگین امتیاز می‌باشد.(توزیع فیلم‌ها در این سه ویژگی) تفکیک‌پذیری در خوشه‌ها به خوبی اتفاق افتاده است و هر کدوم محدوده‌ای از داده‌ها را پوشش می‌دهد. در این نمودار نیز هنگامی‌که بودجه پایین‌تر (در سمت چپ نمودار، مقادیر منفی محور Budget) چند خوشه‌ی مجزا متمرکز شده‌اند که از نظر مدت زمان و امتیاز تفاوت‌هایی دارند، اما فیلم‌هایی با بودجه بالا بیشتر در نواحی سمت راست و بالای نمودار قرار گرفته‌اند و بازه طولانی‌تری از زمان فیلم را پوشش می‌دهد. بنابراین همانطور که در جدول ۴ بیان شد، از نظر بودجه و زمان فیلم تاثیر بسزایی دارد ولی میانگین امتیاز نیز گاهی تاثیر داشته است.

روش دوم)Hierarchical clustering



شکل ۱۳- نمودار تعیین k الگوریتم Hierarchical با استفاده از روش elbow و شاخصsilhouette

در شکل۱۳ مشاهده می‌شود که نمودار elbow (در سمت چپ) هنگامی‌که k=۵ است، پس از آن، کاهش قابل توجهی Inertia صورت نمی‌گیرد. همچنین در نمودار silhouette (در سمت راست) هنگامی که k=۷ بیشترین مقدار ممکن می‌رسد اما برای ۵ خوشه (حدود ۰.۳۱۵) اختلاف قابل توجهی Silhouette (مانند ۶ یا ۷ خوشه) ندارد، در حالی که امتیاز ۴ خوشه به طور محسوسی پایین‌تر است؛ بنابراین با توجه به این دو نمودار مقدار بهینه k در این روش برابر با ۵ خوشه است.



شکل۱۴ - نمودار خوشه‌های الگوریتم Hierarchical برای k=۵

در شکل ۱۴ مشاهده می‌شود که ۵ خوشه متمایز الگوریتم Hierarchical رسم شده است به‌طوریکه محورx بودجه و محور y زمان فیلم و محور z میانگین امتیاز می‌باشد. ویژگی بودجه یکی از مهم‌ترین عامل برای تفکیک است به‌طوریکه خوشه‌ای با رنگ بنفش تیره در مقادیر پایین بودجه، فیلم‌های کم‌هزینه را شامل می‌شود، اما خوشه‌های دیگر در دامنه‌های بالاتر بودجه پوشش داده اند. همچنین تفکیک بسیار خوبی بین خوشه‌ها صورت گرفته است اما همپوشانی در میان خوشه‌های با بودجه متوسط وجود دارد. خوشه‌هایی با رنگ‌های زرد و سبز، به ترتیب، به نظر می‌رسد نماینده فیلم‌هایی میانگین امتیاز بالایی دارند و فیلم‌هایی با مدت زمان طولانی‌تر هستند. بنابراین این روش نیز به خوبی توانسته است خوشه‌ها تفکیک کند به‌طوریکه ویژگی بودجه یکی از مهم‌ترین عامل و دو ویژگی مدت زمان فیلم و میانگین امتیاز نیز به عنوان عوامل مکمل، نقش موثری در تفاوت‌های درونی و ساختار خوشه‌ها است.

در مقایسه دو الگوریتم، به دلیل تخصیص قطعی‌تر و تشکیل خوشه‌هایی با مرزهای شفاف‌تر در فضای ویژگی‌ها، برای شناسایی گروه‌های اصلی (مثل فیلم‌های کم‌هزینه در مقابل پرهزینه) بهترعمل کرد. از سوی دیگر، Hierarchical Clustering توانست با نمایش ساختار درختی، روابط ظریف‌تروهم‌پوشانی‌های ذاتی میان فیلم‌ها (به‌ویژه در بازه بودجه متوسط) را بهتر توضیح دهد. بنابراین با توجه به اهداف این پروژه، K-Means به دلیل سادگی و کارایی بالاتر در خوشه‌بندی سریع، در اولویت قرار گرفت.

بخش چهارم) Neural Network for Revenue Prediction

در بخش چهارم با استفاده از شبکه عصبی، پیش‌بینی درآمد فیلم‌ها صورت می‌گیرد. با استفاده از ویژگی‌ها (در این بخش ملاک فقط ستون‌های عددی نیست و هر ستون که اطلاعات مفید بدهد به مدل اضافه می‌شود. می‌توان از کلاسترینگ هم استفاده کرد اما هدف فقط استفاده بخش قبلی در مدل نیست بلکه هدف در این بخش از نظر من استفاده ازتعداد کم پارامترهای مدل در عین حال بهترین عملکرد مدل حاصل شود، می‌باشد.) ویژگی درآمد همانطور که بخش‌های پیش بررسی شد دارای چولگی شدید و مقادیر صفر ثبت نشده است. اما چون متغیرپاسخ در این بخش پرکردن معنی ندارد بنابراین مقادیر صفر (نشاندهنده‌ی عدم ثبت اطلاعات) از راهکار اول در بخش پیش‌پردازش استفاده می‌شود، سپس از تبدیل لگاریتم برای کاهش اثر پرت استفاده می‌شود.

در این بخش، ابتدا داده‌ها مجددا از فایل اصلی خوانده شدند تا فرآیند پیش‌بینی به صورت مستقل از مراحل قبلی انجام شود اما از نتایج بخش‌های قبلی کاملا استفاده شده است. با توجه به بخش قبلی ویژگی‌های عددی budget، runtime، popularity و vote_average که دارای مقادیر صفر (عدم ثبت اطلاعات) بودند، با میانه پر شدند و با missing indicator اثر گمشدگی آن‌ها نیز تعریف شد. همچنین برای چولگی شدید این متغیرها budget، popularity، vote_count از تبدیل لگاریتم استفاده شد و در ویژگی runtime به دلیل وجود مقادیر پرت از روش winsorization استفاده شد تا مقادیر بزرگ کنترل شود. همچنین ویژگی adult نیز به‌صورت یک متغیر دودویی کد گذاری شد. (همانطور که در جدول ۱، این ویژگی مربوط محتوای مخصوص بزرگسالان است.) و ویژگی belongs_to_collection نیز با عنوان has_collection تعریف شد. همچنین ویژگی genres نیز که مربوط به اطلاعات ژانر است با استفاده از پردازش مناسب خارج شدند و یک لیست شامل ژانرها برای هر فیلم ساخته شد و در نهایت ژانرهای پر تکرار تبدیل به عددی شدند. در ویژگی original_language نیز زبان‌های پرتکرار در نظر گرفته شده‌اند و سپس به صورت یک کدگذاری دودویی برای این ویژگی در نظر گرفته شده است. ویژگی مهم دیگر release_date که به تاریخ تبدیل شد و دو ویژگی release_year، release_month استخراج شده است. همچنین ویژگی ساختاری فیلم is_US_production و num_production_companies و num_languages و genre_count نیز به صورت مناسب مورد آزمون قرار گرفته‌اند. (متغیرهای ترکیبی هم ساختم ولی هیچ کدام به مدل کمک نکرد برای همین حذف کردم چون از همپوشانی همین اطلاعات بود دیگر تحلیل نکردم.)مدل نهایی بعد از آزمون خطا با استفاده از ویژگی‌هایی همانندlog_budget، log_vote_count ، has_collection ، log_popularity، budget_missing،is_US_production و ژانرها و زبان‌های پرتکرار استفاده شده است.

پس از تعریف ویژگی‌ها ابتدا ددیتاست به دو بخش train(۷۰ درصد) و temp (۳۰درصد)تقسیم شدند، سپس بخش temp به طور مساوی به validation (۱۵درصد) و test (۱۵درصد) تفکیک شد. همچنین ویژگی‌ها در مقیاس‌های مختلفی داشتند، بنابراین از روش standardScaler برای نرمال‌سازی داده‌ها استفاده شد.

با توجه به‌صورت مسئله برای پیش‌بینی درآمد، از یک شبکه عصبی پرسپترون چندلایه (MLP) استفاده شد. همچنین از روش early stopping برای جلوگیری از بیش‌برازش استفاده شد. پس از اتمام آموزش، عملکرد مدل روی داده‌های آزمون که در طول آموزش هرگز دیده نشده بودند، ارزیابی شد.

جدول ۵ – نتایج معیارهای ارزیابی روی مجموعه آزمون

شاخص ارزیابی	مقدار
Mean Squared Error (MSE)	۱۳.۸۸
R-squared (R^2)	۰.۶۲

بر اساس جدول۵، نتایج ارزیابی روی مجموعه آزمون، مقدار MSE برابر با ۱۳.۸۸حاصل شده است که نشان‌دهنده میزان خطای متوسط پیش‌بینی‌ها در مقیاس لگاریتمی درآمد است. همچنین مقدار ضریب تعیین برابر با ۰.۶۲ گزارش شده است به این معنا که مدل می‌تواند حدود ۶۲درصد از واریانس درآمد فیلم‌ها را با استفاده از ویژگی‌های استفاده شده در مدل توضیح دهد.

جدول۶- تحلیل همبستگی ویژگی‌ها باRevenue

ویژگی‌ها	همبستگی
log_revenue	۱,۰۰۰۰۰۰
log_vote_count	۰,٦٤۰٦۹۲
log_popularity	۰,٥۸۰۸۸۷
is_US_production	۰,۲۷٤۳۲٥
log_budget	۰,۱۹۲٦۳۱
has_collection	۰,۱۷٥٦۳٥
budget_missing	-۰,٦۱٦٤٦٦

همچنین در جدول ۶ بررسی همبستگی بین برخی ویژگی‌ها نشان می‌دهد که log_budget، log_vote_count، log_popularityبیشترین تاثیر بر روی مدل می‌گذارد و سایر ویژگی‌ها نیز نقش تکمیلی را دارند. همچنین در ویژگی budget_missing(عدم ثبت اطلاعات بودجه) همبستگی منفی قوی با درآمد دارد. بسیاری از فیلم‌های کم‌هزینه اطلاعات مالی کاملی در این دیتاست وجود ندارد.

بنابراین در این پروژه با تحلیل اکتشافی، پیش‌پردازش دقیق داده‌ها و خوشه‌بندی فیلم‌ها بر اساس بودجه، مدت‌زمان و میانگین امتیاز، پنج گروه معنادار شناسایی شد که تفاوت آن‌ها مربوط به سطح بودجه و ساختار محتوایی است و با استفاده از شبکه عصبی چندلایه، مدل پیش‌بینی درآمد فیلم توانست ۶۲٪ از واریانس درآمد را توضیح دهد. در مجموع، ترکیب خوشه‌بندی و مدل‌سازی شبکه عصبی نشان داد بودجه، میزان محبوبیت و تعداد آرا مهم‌ترین عوامل تعیین‌کننده در درآمد فیلم‌ها هستند.